

データブリックスを使ってみよう

ETL, BI, MLなどのあらゆる分析ユースケースを一つのプラットフォームで実現し、組織全体でのデータとAIの効率的な利活用を促進

弥生 隆明 / Paulo Gutierrez

データブリックス・ジャパン株式会社 ソリューションアーキテクト

アジェンダ

- 会社概要
- AI・機械学習プロジェクトにおける課題
- レイクハウスプラットフォーム

自己紹介



弥生 隆明 (やよい たかあき)
ソリューションアーキテクト

- 前職はコンサルティングファーム、総合電機メーカーにてデータ分析・Webサービス構築などに従事。インド赴任経験あり。
- 最近驚いたこと：インドカレーのサグカレーが好きなのですが、先日インド人の知り合いから「サグはほうれん草ではなくて草、ほうれん草はパラク」と教えてもらったことです。

About Me

Paulo Gutierrez (パウロ)
ソリューションアーキテクト

Spark, Flink, Arrow, Elasticsearch, MongoDB など

カメラ、2輪車、コーヒー、自作キーボード、アウトドア



 @tokyodataguy

 @juanpaulo

アジェンダ

- 会社概要
- AI・機械学習プロジェクトにおける課題
- レイクハウスプラットフォーム



データ&AIカンパニー



レイクハウス

データ、分析、AIに関わるワークフローを統合する
シンプルなプラットフォーム

顧客数

5000+

世界中で利用

オリジナルの開発者が設立



米本国社: Databricks Inc.

設立: 2013年

所在地: アメリカ カリフォルニア州 サンフランシスコ市

社員数: 2,000 以上

拠点数: 11ヶ国 16拠点

沿革: カリフォルニア大学バークレー校から発祥

代表者: アリ・ゴディシ(共同設立者 & CEO)

主要な指標

5,000 以上の顧客

450 以上のパートナー

ARR(年間定額収益)は 約430億円
(2021年1月)

シリーズGの資金調達により 約3兆円 市場価値
(2021年2月)

事業戦略

AI, ビックデータ に特化

クラウド上のみで提供

(Microsoft Azure, AWS, GCP, Alibaba Cloud)

積極的な オープンソース化



市場における評価

ガートナー社 マジック・クアドラント・レポート
「2021年 データサイエンス & 機械学習 部門」
"リーダー" 企業に指名(3年連続)

チャレンジャー

リーダー



ニッチプレイヤー

ビジョナリー

あらゆる産業にサービスを提供しています

ヘルスケア・ライフサイエンス



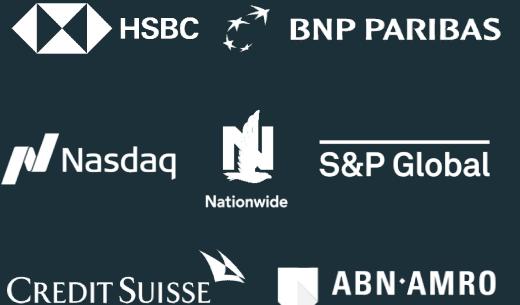
製造業・自動車



メディア・エンターテイメント



金融



公共



小売



エネルギー



デジタルネイティブ



アジェンダ

- 会社概要
- AI・機械学習プロジェクトにおける課題
- レイクハウスプラットフォーム

未来はすぐそこに来ています。しかし、すべての人が享受できている訳ではありません

83% のCEOは戦略的にAIを優先すべきと述べています

MIT Sloan
Management Review

\$3.9T
約425兆円

Gartner.

が2022年までにAIによつてもたらさられるビジネス価値となります

85% のビッグデータプロジェクトが失敗しています

Gartner.

87% のデータサイエンスプロジェクトが本格運用に到達していません

VB



データプラットフォームの 進化の過程

なぜ、AI・機械学習プロジェクトが暗礁に乗り上げてしまうのか？



データウェアハウス 1990年代～

Pros

- 偉大なるビジネスインテリジェンス (BI) アプリケーション

Cons

- 限定的な機械学習(ML)のサポート
- SQLインターフェースのみを備えたプロプライエタリなシステム

データレイク

2010年代～

Pros

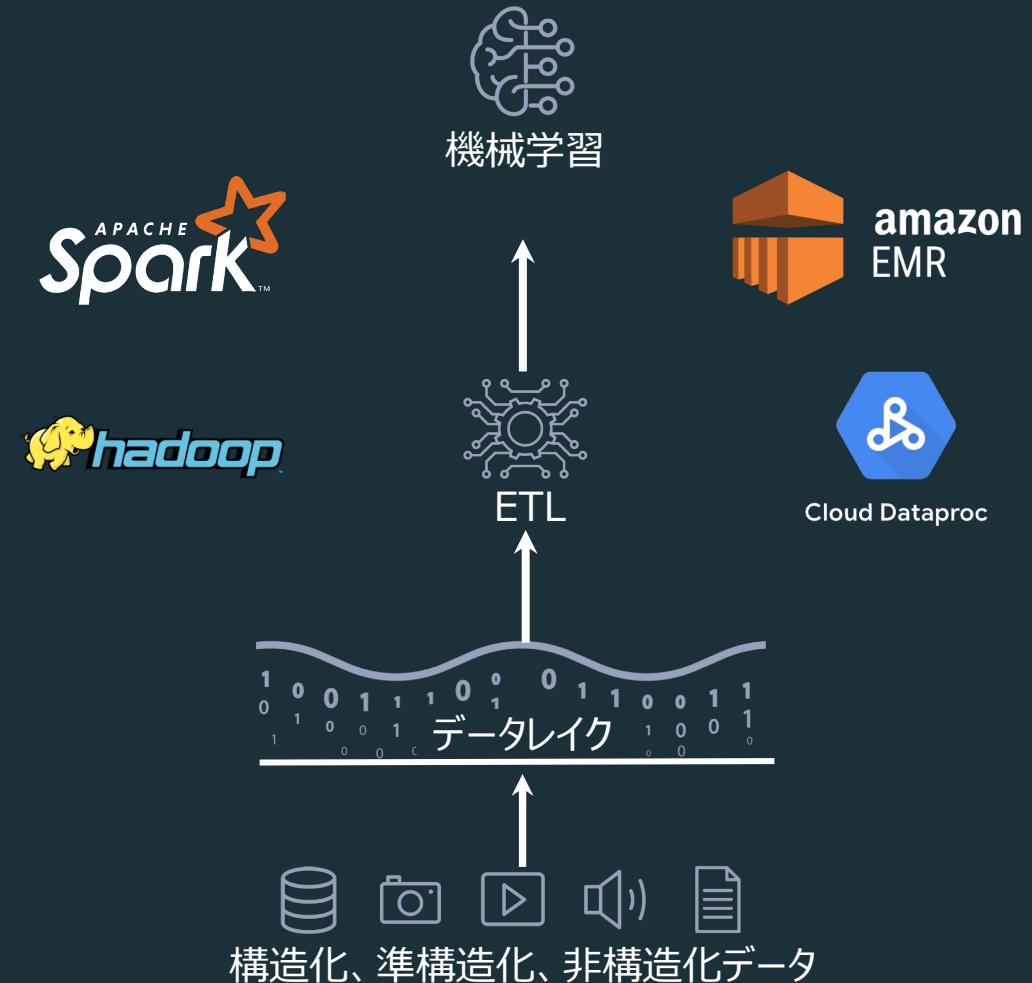
MLをサポート

オープンなフォーマット、
巨大なエコシステム

Cons

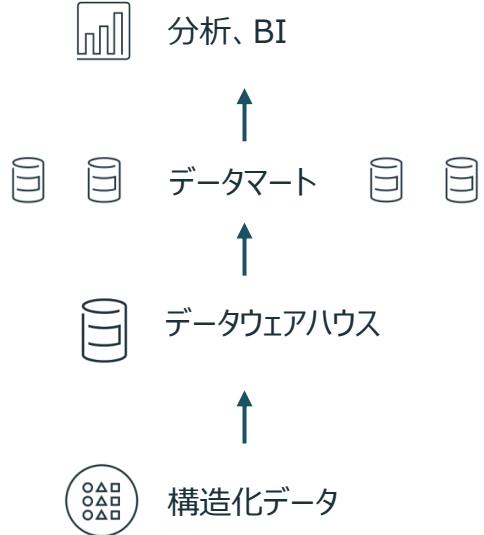
貧弱なBIサポート

複雑化したデータ品質問題

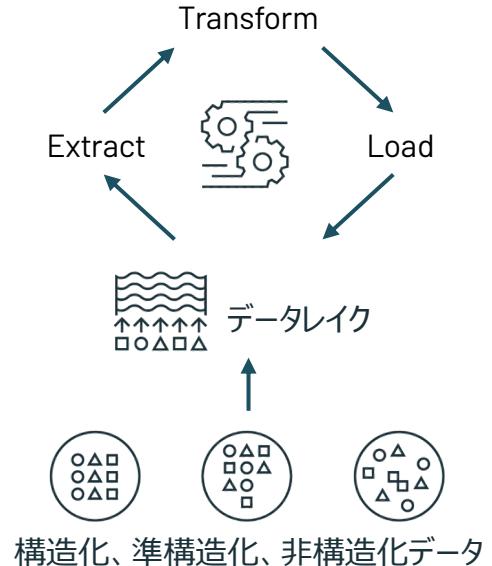


そして現在 多くの企業がデータウェアハウス・データレイクと格闘しています

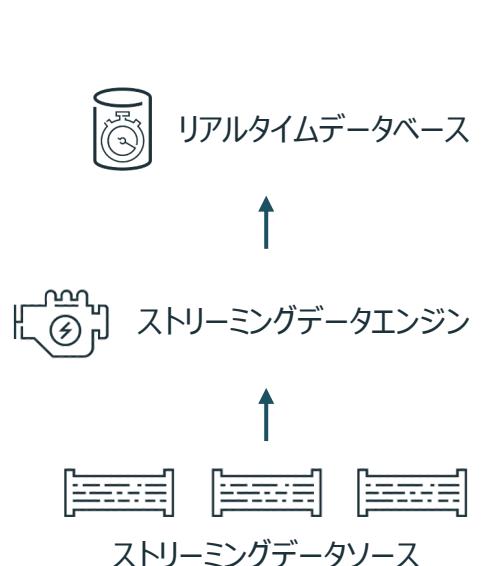
データウェアハウス



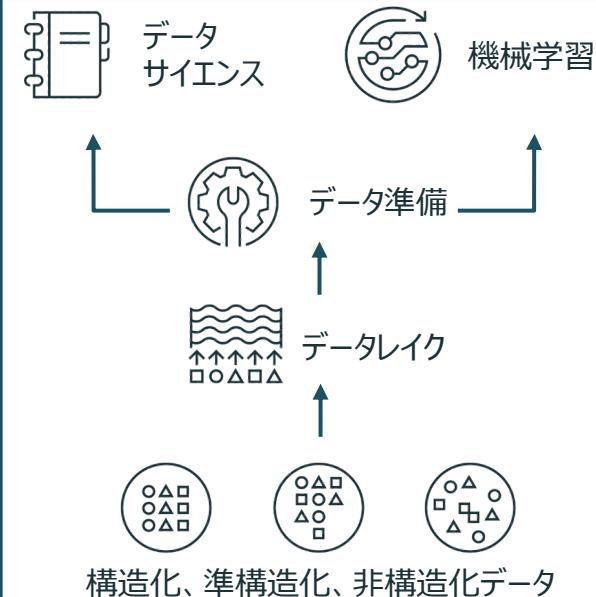
データエンジニアリング



ストリーミング



データサイエンス & 機械学習



サイロ化はデータアーキテクチャをより複雑にしています

そして現在 多くの企業がデータウェアハウス・データレイクと格闘しています

データウェアハウス

データエンジニアリング

ストリーミング

データサイエンス & 機械学習

断続したシステムとプロプライエタリなデータフォーマットはシステムの統合を妨げています

Amazon Redshift
Azure Synapse
Snowflake
SAP

Teradata
Google BigQuery
IBM Db2
Oracle Autonomous Data Warehouse

Hadoop
Amazon EMR
Google Dataproc

Apache Airflow
Apache Spark
Cloudera

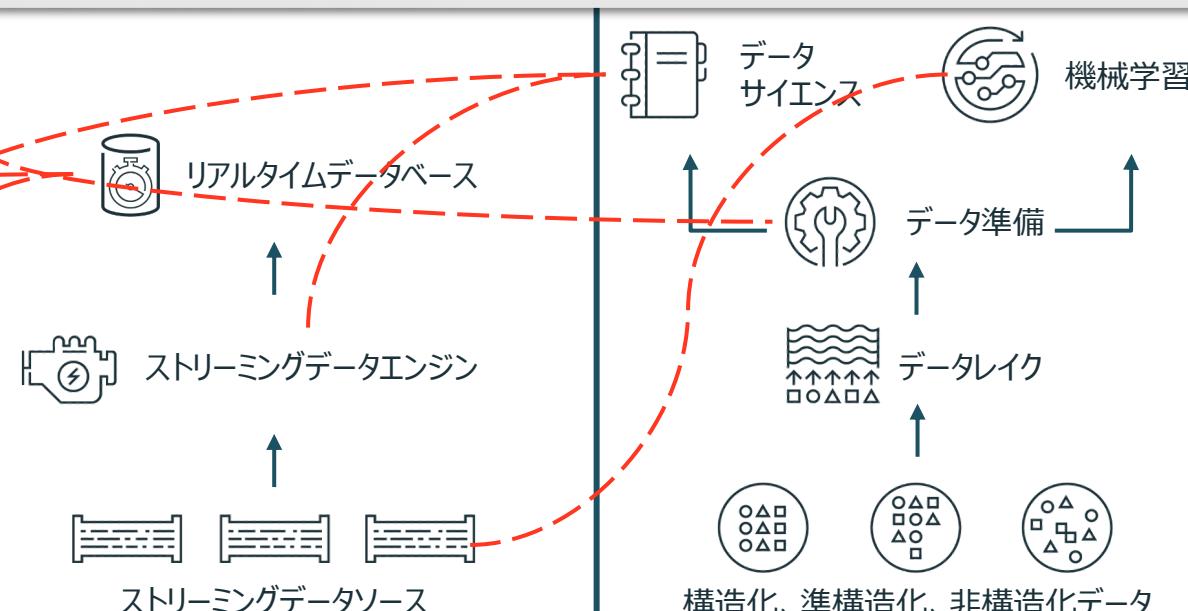
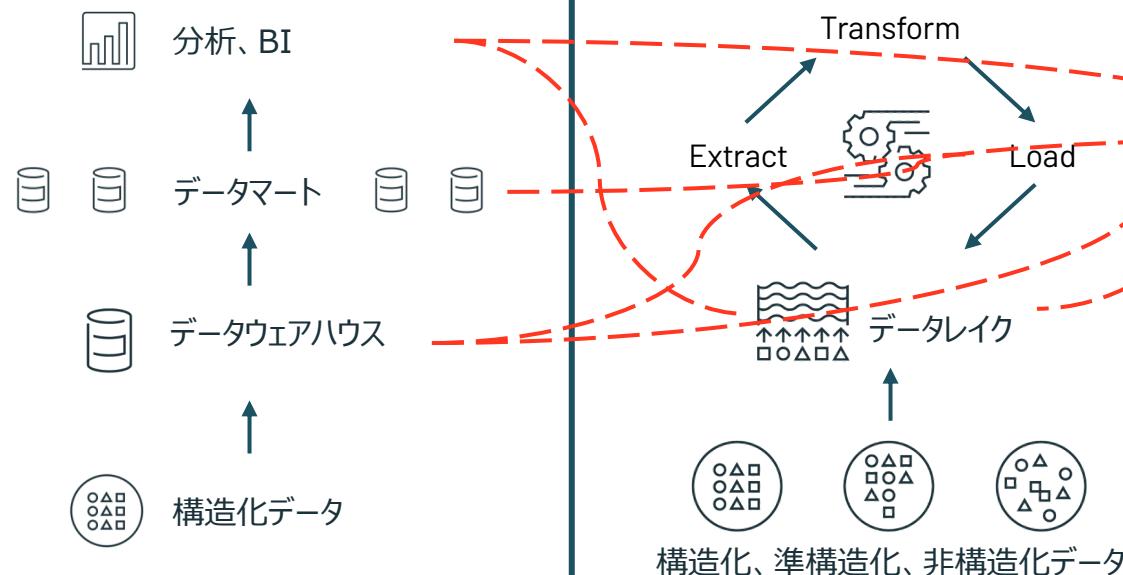
Apache Kafka
Apache Flink
Azure Stream Analytics
Tibco Spotfire

Apache Spark
Amazon Kinesis
Google Dataflow
Confluent

Jupyter
Azure ML Studio
Domino Data Labs
TensorFlow

Amazon SageMaker
MatLAB
SAS
PyTorch

サイロ化はデータアーキテクチャをより複雑にしています



そして現在 多くの企業がデータウェアハウス・データレイクと格闘しています

データウェアハウス

データエンジニアリング

ストリーミング

データサイエンス & 機械学習

サイロ化したチームの生産性は低下します



データアナリスト



データエンジニア



データエンジニア



データサイエンティスト

断絶したシステムとプロプライエタリなデータフォーマットはシステムの統合を妨げています

Amazon Redshift

Azure Synapse

Snowflake

SAP

Teradata

Google BigQuery

IBM Db2

Oracle Autonomous Data Warehouse

Hadoop

Amazon EMR

Google Dataproc

Apache Airflow

Apache Spark
Cloudera

Apache Kafka

Apache Flink
Azure Stream Analytics
Tibco Spotfire

Apache Spark

Amazon Kinesis
Google Dataflow
Confluent

Jupyter

Azure ML Studio
Domino Data Labs
TensorFlow

Amazon SageMaker

MatLAB
SAS

PyTorch

サイロ化はデータアーキテクチャをより複雑にしています

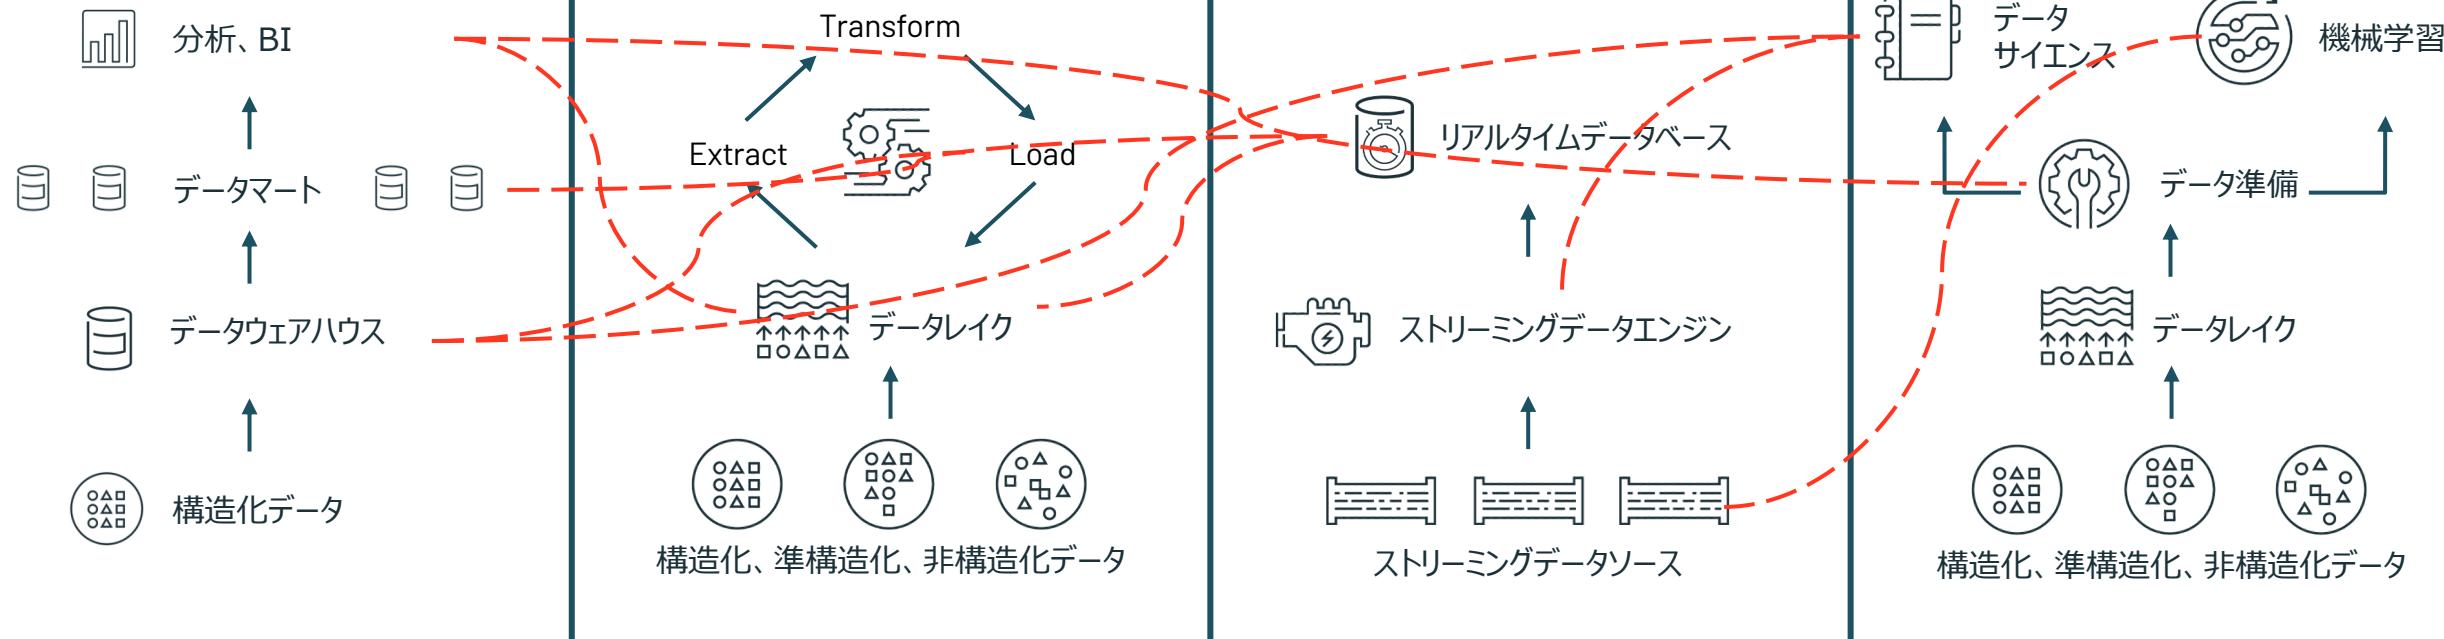
分析、BI

データマート

データウェアハウス

構造化データ

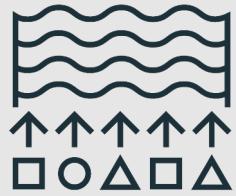
構造化、準構造化、非構造化データ



アジェンダ

- 会社概要
- AI・機械学習プロジェクトにおける課題
- レイクハウスプラットフォーム

データ
レイク



レイクハウス

データ、分析、AIに関わるすべての活動を
統合するプラットフォーム

データ
ウェアハウス





databricks

レイクハウスプラットフォーム

シンプル

オープン

コラボレーティブ

データエンジニアリング

BI & SQL
アナリティクス

リアルタイムデータ
アプリケーション

データサイエンス &
機械学習

データマネジメント & ガバナンス



DELTA LAKE

オープンなデータレイク



構造化データ



準構造化データ



非構造化データ



ストリーミング



Google Cloud

Databricksの提供する機能

全データ及び機械学習ライフサイクルをサポートする レイクハウスプラットフォーム

1

高品質なデータに
アクセス可能



さまざまなデータソースから集約された
高品質なデータセットにアクセス可能

2

データサイエンスチーム
の生産性向上



Databricks
データサイエンス
ワークスペース
(MLランタイム上で稼働)

1つのプラットフォームにて多種多様な
ツール・言語・フレームワークを
利用可能

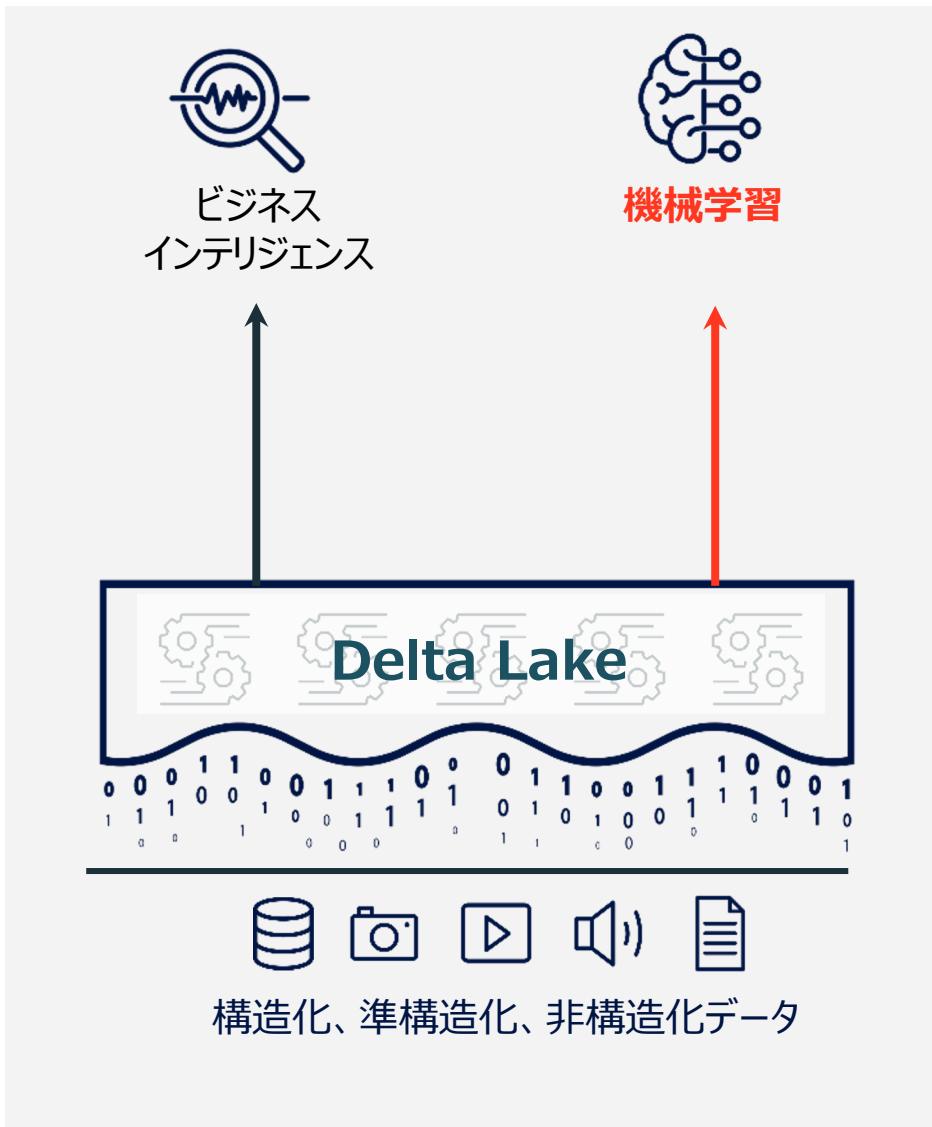
3

標準化された
機械学習
ライフサイクル

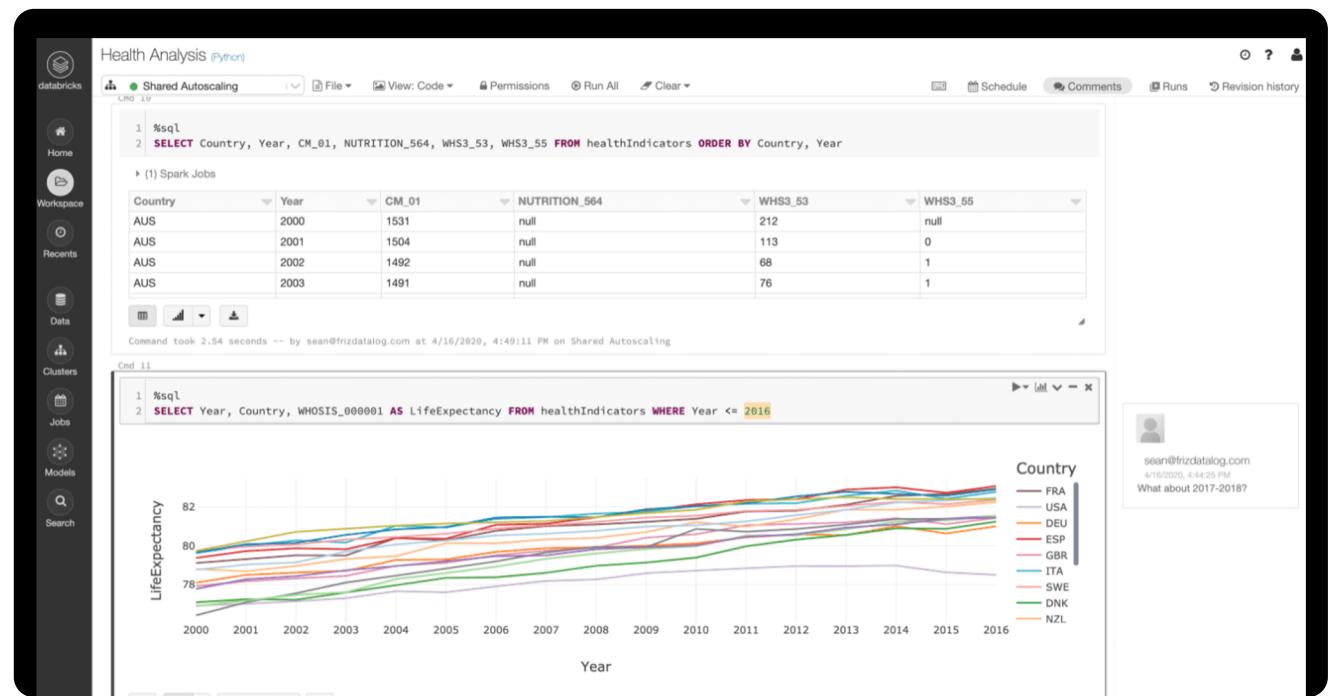


機械学習モデルをステージングから本番環境へ
シームレス・セキュアに連携可能

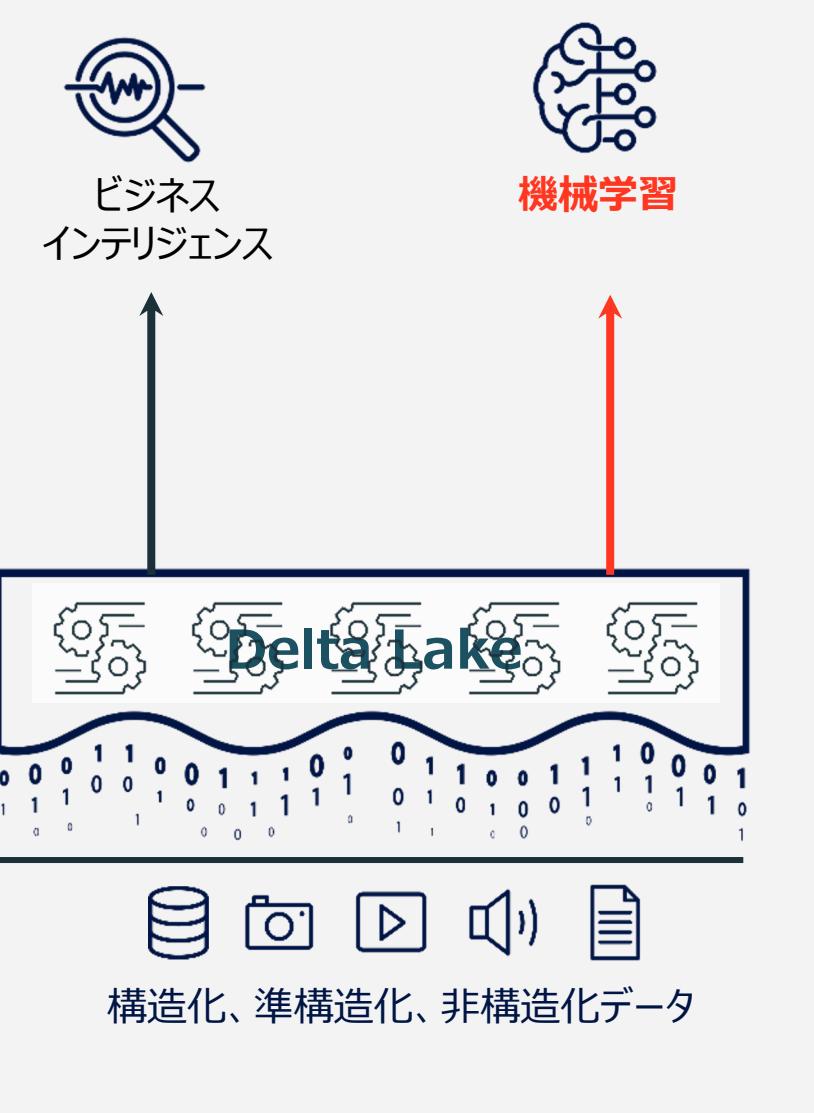
レイクハウスにおけるデータサイエンス



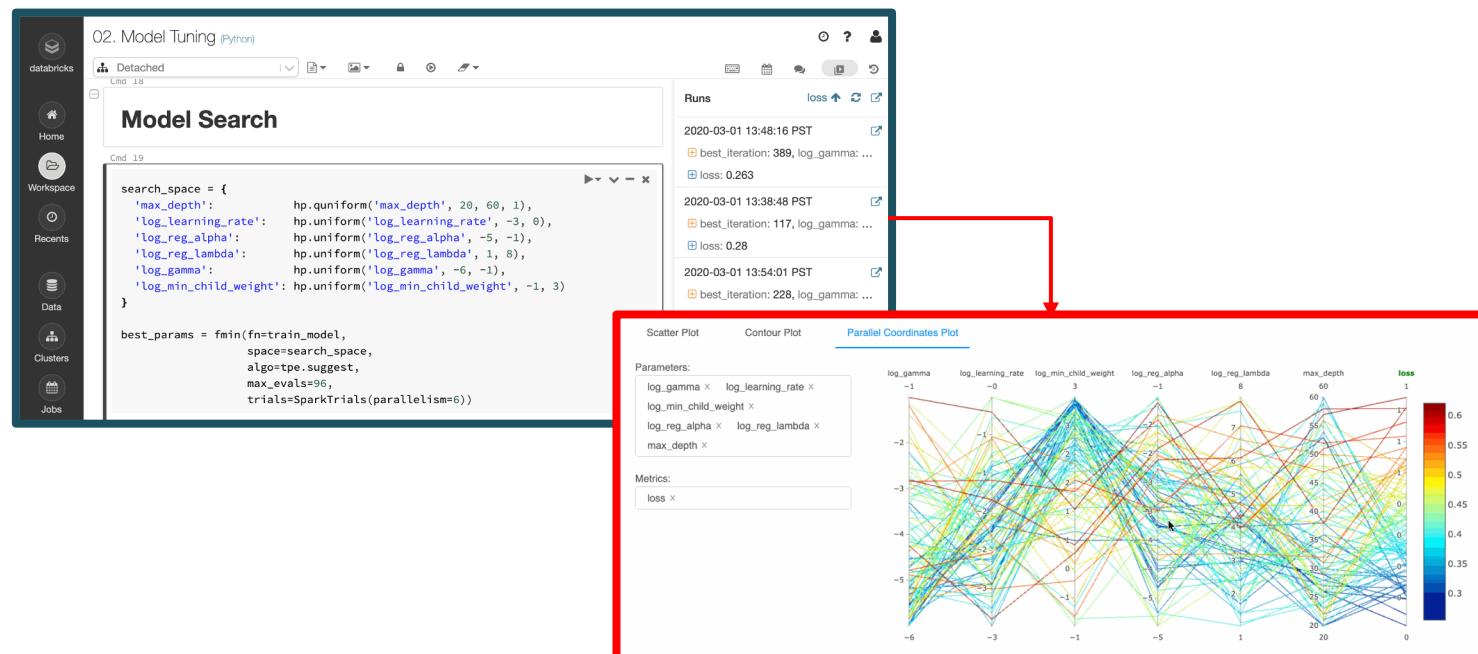
- インタラクティブな分析に適したコラボレーティブノートブックとダッシュボード
- Python、Java、R、Scala、SQLのネイティブサポート
- Delta Lakeデータのネイティブサポート



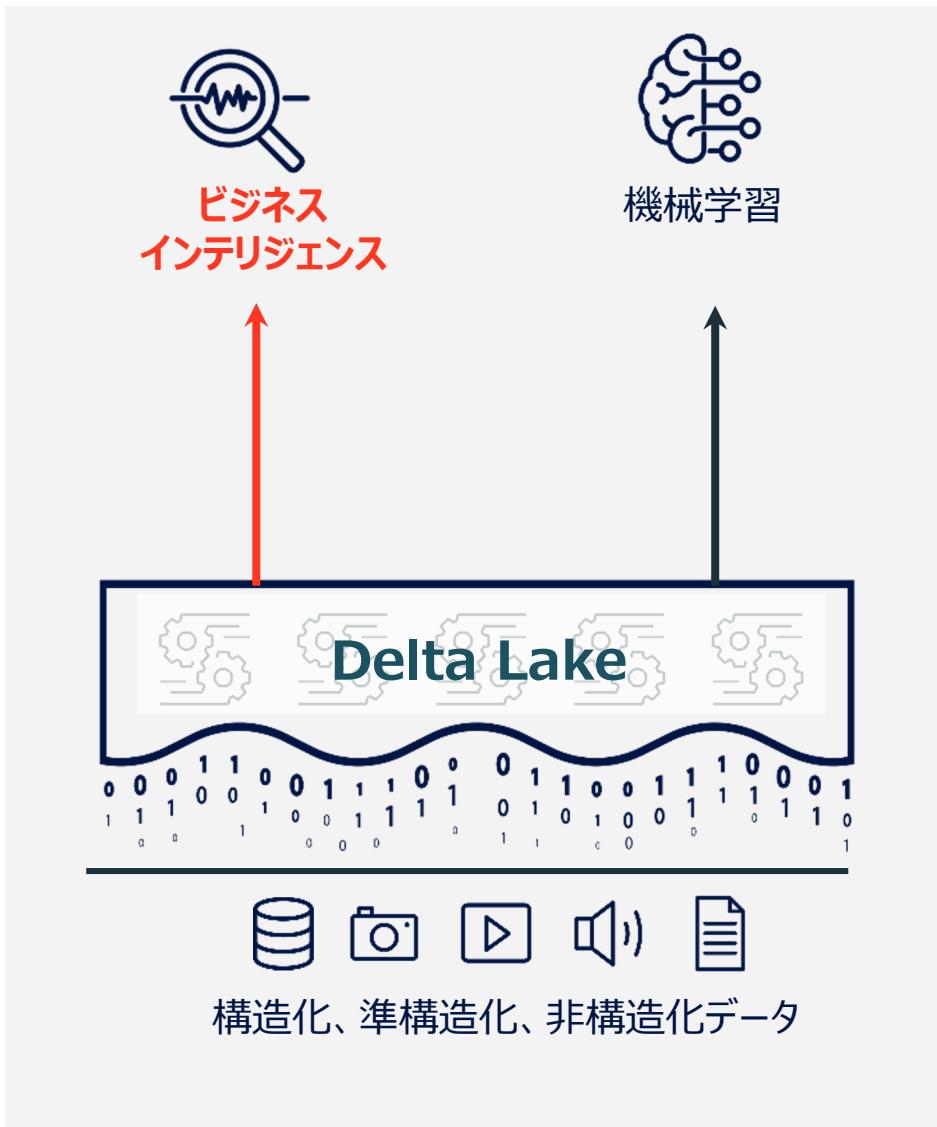
レイクハウスにおける機械学習



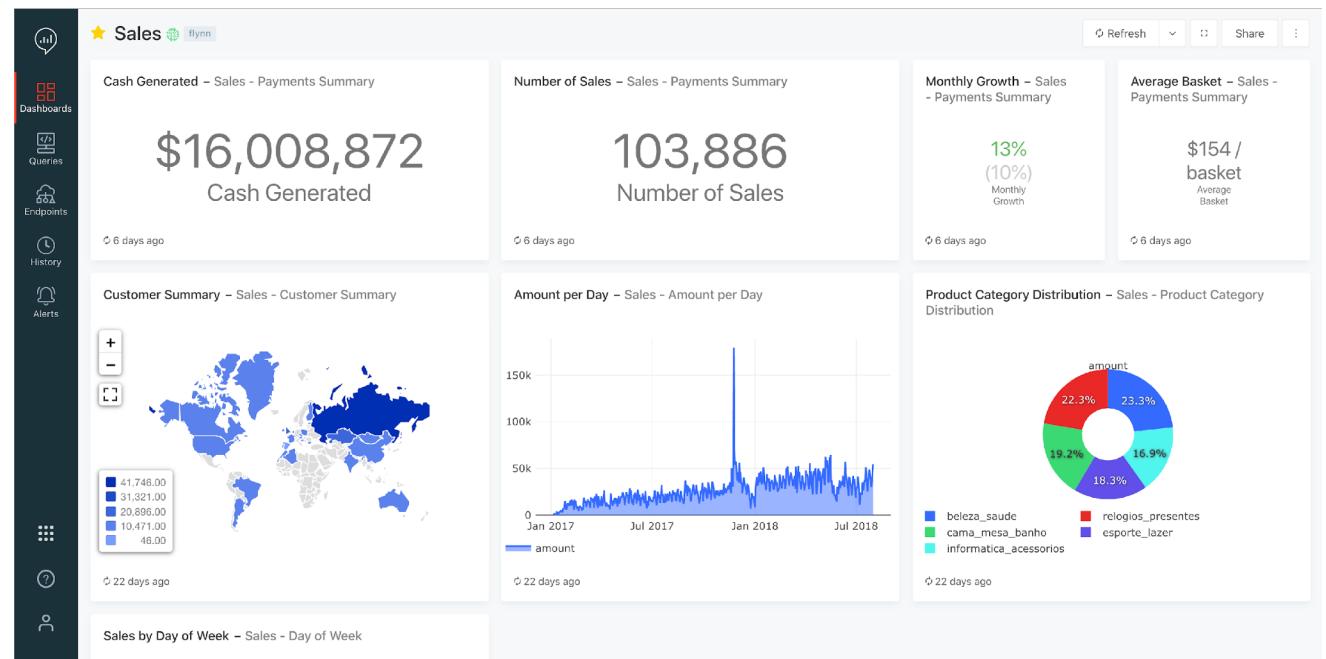
- モデルレジストリ、モデルの再現性、プロダクションへの移行
- Delta Lakeのデータ履歴を活用した再現性の確保



レイクハウスにおけるBI



- Delta Lakeにより実現される高性能なBI、Databricks SQL
- SQLインターフェースのネイティブサポート及びBIツールによるDeltaへの直接接続をサポート



ハンズオンの概要

データブリックスを使ってみよう！

目的：

データブリックスワークスペース上でハンズオンを実施いただき、基本操作を体験していただく

対象：

データ分析に携わる方

アジェンダ：

ワークスペースにおけるノートブックの操作を通じて、データブリックスのメリットを体験いただきます。

1. 探索的データ分析(EDA)、ETL、機械学習モデル構築、モデル配備、BIまでを一つのプラットフォームで実行できます
2. インフラの管理が簡単です
3. データベースのインストールが不要です
4. リモートワークでのコラボレーションが簡単です
5. ノートブックのバージョンが自動で管理されます
6. プログラミング言語を柔軟に切り替えることができます
7. データを簡単に可視化できます
8. 大量データを高速に処理できます

JEDAIは、データブリックスを最大限ご活用いただくための有益な情報をご提供するとともに、ユーザー同士がつながり、関係を深めることができる場として活動いたします。

2021年は5回の開催を予定しています。ぜひお気軽にご参加ください。

Community Guide



データブリックス・ジャパン株式会社
Senior Customer Success Engineer

徳元 大輔

通信事業者で様々な業務を経験した後にビッグデータ業界に。現在は Databricks Japan でポストセルスの頼れるなんでも屋さんを目指している。趣味は、飲み食歩き・キックボクシングと過度なエクササイズ・海外SF小説。好きな映画：ブレードランナー、パルブフィクション。座右の銘：無欲は怠惰の元である。

プログラム概要

お客様セッション

5・7・9・11・1月開催（予定）

データブリックスをご利用頂いてるお客様企業やデータ&AIのプロフェッショナルをお招きして、実際現場で苦悩されている点や、さらには普段他では話すことのできないハプニング、ココでしか聞けない開発秘話など、存分にお話いただきます。セッションの他にも、Q&Aの時間をたっぷり設け、オンラインの枠を超えた、できる限りインタラクティブなコミュニケーションが取れるようにいたします。

テーマ別セッション

6・8・10・12月開催（予定）

データプロジェクトにおける世界の最新トレンドからAI/機械学習プロジェクトの実運用まで、毎回テーマを設定し、弊社のパートナー様や弊社のデータ&AI プロフェッショナルが、ご説明します。セッションの他にも、Q&Aの時間をたっぷり設け、オンラインの枠を超えた、できる限りインタラクティブなコミュニケーションが取れるようにいたします。

コミュニティへの登録方法

コミュニティの運営は「Connpass」を利用いたします。
こちらの登録は、Eメールアドレスに加え、各種ソーシャルアカウント (Twitter, Facebook)との連携が可能です。

ご登録はこちら> <https://jedai.connpass.com/>

Thank you